Generatív AI és alkalmazások

Pál László

Sapientia EMTE, Csíkszereda

2026

A kőbaltától a generatív AI-ig

15. század

1879

1878

1903

1920

1935

1990

2022

AI kronológia

- **1950-es–60-as évek: a kezdetek**
  - 1950: Turing teszt
  - 1955: MI születése (Dartmouth)
  - 1957: Perceptron
  - 1958: Lisp nyelv
  - 1965: ELIZA – első chatbot
- **1970–80-as évek: szakértői rendszerek**
  - 1972: Dendral – szakértői rendszer
  - 1980-as évek: „AI Winter”
  - 1986: Backpropagation
- **1990–2000-es évek: gépi tanulás**
  - NLP, Computer Vision (CNN)
  - 1997: Deep Blue sikere
- **2010-es évek: Deep Learning**
  - 2012: AlexNet – CNN áttörés
  - 2017: Transformer architektúra
- **2022+: Generatív AI kora**
  - 2022: ChatGPT
  - 2023: GPT-4, Claude, Gemini
  - 2024: Claude 3.5, Llama 3, Sora
  - 2025: DeepSeek R1, GPT-5
  - 2026: Gemini 3.1, Claude 4

ML módszerek kategóriái

Felügyelt tanulás

Osztályozás, regresszió
Címkézett adatokból tanul

Felügyelet nélküli tanulás

Klaszterezés, dimenziócsökkentés
Rejtett mintákat keres

Megerősítéses tanulás

Játékok, robotika, optimalizálás
Jutalom alapján tanul

Mélytanulás (Deep Learning)

CNN (képfelismerés)
RNN / LSTM (szöveg, idősor)
Transformer

Generatív AI

Nagy nyelvi modellek (LLM)
Képgenerálás, hangszintézis, videó

A neurális hálók fejlődése

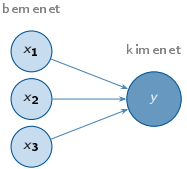

Perceptron (1957)

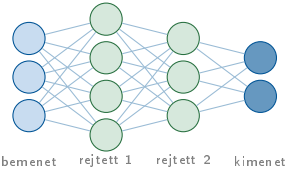

Többrétegű perceptron (MLP)

Több réteg → nemlineáris problémák

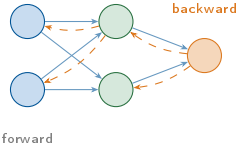

Backpropagation (1986)

Hiba visszaterjesztése a súlyok frissítéséhez

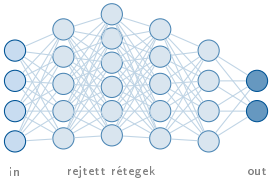

Mély neurális háló (DNN)

Nagy nyelvi modellek (LLM)

- **LLM**: transformer alapú neurális háló, amely a **következő token valószínűségét** tanulja
- **Transformer architektúra** – a modern LLM-ek alapja (2017, Google: „*Attention is All You Need*")
- Hatalmas szövegkorpuszon tanítják (internet, könyvek, kód) – milliárdos paraméterszám

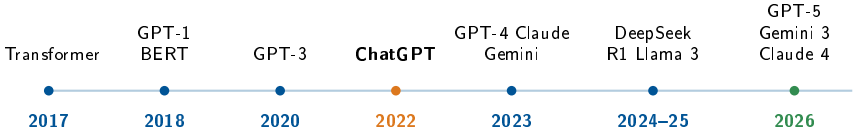

LLM – Lehetőségek és kihívások

Lehetőségek

- Szöveggenerálás
- Fordítás
- Összefoglalás
- Kódelőállítás
- Osztályozás, kategorizálás
- Sentiment elemzés
- Chatbotok, asszisztensek

Kihívások

- Költséges (erőforrás-igény)
- **Hallucinálás**
- Megbízhatóság, pontosság
- Adatvédelem, etika

Alkalmazások

- Egészségügy, pénzügy
- Marketing, oktatás
- Szoftverfejlesztés

Hogyan működik egy LLM?

1. Tokenizálás
2. Embedding
3. Transformer rétegek
4. Valószínűségi eloszlás
5. Dekódolás → Kimenet

Következő szó predikció

„The cat sat on the ...”

mat	45%
floor	22%
table	15%
roof	8%
...	...

A modell mindig a legvalószínűbb következő tokent választja (vagy mintavételez).

Alapfogalmak

Token

- A szöveg legkisebb egysége
- 1 token $\approx$ 0,75 szó (kb. 4 karakter)
- A modell tokeneket olvas, nem szavakat

Kontextus ablak

- Amit a modell egyszerre „lát”
- GPT-3: 4k $\rightarrow$ Gemini 3: **1 000 000** token
- 1M token $\approx$ **10 könyv** (750k szó)
- Nem fér bele $\rightarrow$ „elfelejti”

Temperature

- Generálás véletlenszerűsége
- 0 = determinisztikus (kódoláshoz)
- 1 = kreatív (ötleteléshez)

Hallucinálás

- Magabiztosan állít valótlant
- Nem hazugság: statisztikailag valószínű szöveget generál
- **Mindig ellenőrizz!**

RAG – Retrieval-Augmented Generation

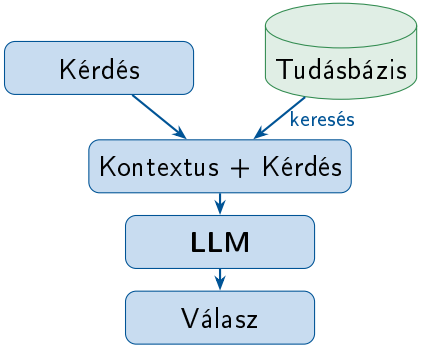

Mi ez?

A modell saját dokumentumokból keres releváns részleteket, és azok alapján válaszol.

Miért fontos?

- Csökkenti a hallucinálást
- Naprakész tudás
- Nem kell újratanítani

Fine-tuning – Finomhangolás

Mi ez?

Egy előtanított modell **további tanítása** saját adatokon, hogy jobban illeszkedjen egy konkrét feladathoz.

Mikor érdemes?

- Speciális szakterület (orvosi, jogi)
- Egyedi stílus vagy formátum
- Nagy mennyiségű saját adat

RAG vs Fine-tuning

	RAG	**Fine-tune**
Költség	Alacsony	Magas
Frissesség	Azonnali	Újratanítás
Pontosság	Jó	Nagyon jó
Beállítás	Egyszerű	Összetett

A gyakorlatban a **RAG** az elterjedtebb megoldás – gyorsabb, olcsóbb, rugalmasabb.

Multimodalitás

Mi ez?

Egyetlen modell **többféle** bemenetet és kimenetet kezel:

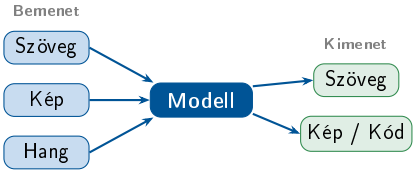

Multimodális modellek

- **GPT-5 / o3** – szöveg, kép, hang
- **Gemini 3** – szöveg, kép, hang, videó
- **Claude 4** – szöveg, kép, kód

Példák a gyakorlatban

- Kép leírása szöveggel
- PDF dokumentum feldolgozás
- Hangfelvétel elemzése
- Videó összefoglalás

AI ágensek

Mi az ágens?

Olyan AI rendszer, amely **önállóan tervez és cselekszik**: eszközöket használ, döntéseket hoz, és iteratívan oldja meg a feladatot.

Képességek

- Webkeresés, fájlkezelés
- Kódfuttatás
- API-k hívása („tool use”)
- Többlépéses feladatok

Példák

- **Claude Code** – programozó ágens
- **Devin** – szoftverfejlesztő ágens
- **Manus** – általános célú ágens
- **OpenAI Operator** – böngésző ágens

MCP – Model Context Protocol

Mi ez?

Nyílt szabvány (Anthropic, 2024), amely egységes módon kapcsolja össze az LLM-eket külső eszközökkel és adatforrásokkal.

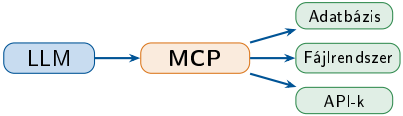

Miért fontos?

- Egy szabvány, sok eszköz
- Bármely LLM használhatja
- Kliens–szerver architektúra
- Növekvő ökoszisztéma

Analógia: ahogy az **USB** szabványosította a hardver csatlakoztatást, az **MCP** szabványosítja az AI eszközökhöz való hozzáférést.

Vibe coding – AI-asszisztált programozás

Mi ez?

Természetes nyelven leírjuk, **mit** szeretnénk, és az AI megírja a kódot. A hangsúly az eredményen van, nem a szintaxison.

Fontos

- Nem váltja ki a programozási tudást
- Megérteni és ellenőrizni kell a kódot
- Nagyon hatékony prototipizáláshoz

Eszközök

- **GitHub Copilot** – kódkiegészítés IDE-ben
- **Cursor** – AI-native szerkesztő
- **Claude Code** – terminál alapú ágens
- **Windsurf** – AI IDE
- **Gemini Code Assist**

A kifejezést **Andrej Karpathy** használta először, 2025 februárjában.

A modellek világa 2026-ban

Modell	Jellemzők	Fejlesztő
GPT-5 / o3	Legnépszerűbb, multimodális, reasoning	OpenAI
Claude 4 (Opus/Sonnet)	Hosszú kontextus, precíz, kód, ágensek	Anthropic
Gemini 3	1M kontextus, multimodális, „gondolkodó”	Google
Grok 4	Valós idejű X adatok, reasoning	xAI
Llama 4	Nyílt forráskódú, lokálisan futtatható	Meta
DeepSeek R1/V3	Erős kód/matek, nyílt, költséghatékony	DeepSeek
Mistral Large	Európai, hatékony, többnyelvű, nyílt	Mistral AI

Modellek funkciók szerint

Szöveg / Chat

ChatGPT, Claude, Gemini, Grok, DeepSeek

Programozás

Claude Code, GitHub Copilot, Cursor, Gemini Code Assist, Windsurf, Antigravity

Képgenerálás

DALL·E 3, Midjourney, Stable Diffusion, Flux, Ideogram

Hang / Beszéd

OpenAI Whisper (STT), ElevenLabs (TTS), NotebookLM

Videó

Sora (OpenAI), Runway, Kling, Veo 2 (Google)

Zene

Suno, Udio

A piac rendkívül gyorsan változik – heti szinten jelennek meg új modellek és funkciók.

Lokális modellek és Hugging Face

Miért lokális modell?

- Adatvédelem (adat nem hagyja el a gépet)
- Nincs előfizetési díj
- Offline működés
- Testreszabhatóság

Futtatókörnyezetek

- **Ollama** – egyszerű CLI
- **LM Studio** – grafikus felület
- **llama.cpp** – optimalizált futtatás

Hugging Face

- Az AI közösség „GitHubja”
- Modellek, adatkészletek, demók
- 100 000+ modell elérhető

Népszerű nyílt modellek

- **Llama 4** (Meta) – Scout, Maverick
- **Mistral Large** – többnyelvű
- **Phi-4** (Microsoft) – kisméretű
- **Gemma 3** (Google) – nyílt
- **DeepSeek R1/V3** – kód/matek

Prompt engineering

Prompt

Az utasítás vagy kérdés, amit a nyelvi modellnek adunk, hogy a **legjobb választ** kapjuk.

Prompt engineering

Hogyan fogalmazzuk meg az utasítást a **leghatékonyabban**:

- Megfelelő kontextus
- Egyértelmű elvárások
- Struktúra és formátum

Technikák

- **Zero-shot** – utasítás példa nélkül
- **Few-shot** – néhány példával
- **Chain of Thought** – lépésről lépésre
- **Persona** – szerep megadása
- **Negatív utasítás** – mit ne tegyen
- **Reflexion** – önellenőrzés

Részletek az **1. feladatban** (Promptolás).

Google Gemini

Mi ez?

A Google multimodális AI modellje és chatfelülete.

- Ingyenesen elérhető
- Google fiókkal használható
- Szöveg, kép, dokumentum, kód

Képességek

- PDF feldolgozás
- Kép elemzése
- Kódgenerálás
- Google szolgáltatások integrációja

`https://gemini.google.com`

Használat: jelentkezzetek be a **saját email** címetekkel.

Google Colab

Mi ez?

Felhőalapú **Python notebook** környezet, közvetlenül a böngészőben.

- Ingyenes GPU/TPU hozzáférés
- Nincs telepítés
- Google Drive integráció

Mire használjuk?

- Adatelemzés (pandas, matplotlib)
- Gépi tanulás (scikit-learn)
- AI modell futtatás
- Megosztható notebookok

`https://colab.research.google.com`

Használat: File → Upload notebook, majd saját email-lel belépés.

A képzés tartalma

	Tevékenység	Időtartam	Eszköz
0.	Bevezető előadás	∼30 perc	Prezentáció
1.	Promptolás (Prompt engineering)	∼70 perc	Gemini
	— *Szünet* —	*10 perc*	
2.	AI alapú részvényelemzés	∼100 perc	Colab + Gemini
	— *Ebédszünet* —	*30 perc*	
3.	Airbnb szálláshelyek elemzése	∼115 perc	Colab + Gemini
	Összesen	**∼355 perc**	

Anyagok elérhetősége:

GitHub: `https://github.com/pallaszlo/ai-kepzes`

Eszközök:

`https://gemini.google.com`

`https://colab.research.google.com`

Köszönöm a figyelmet!

Kérdések?

Könyvészet

- https://platform.openai.com/docs
- https://docs.anthropic.com/
- https://ai.google.dev/gemini-api/docs
- https://huggingface.co/learn/nlp-course
- https://modelcontextprotocol.io/
- Vaswani et al. (2017): „Attention is All You Need”
- https://cookbook.openai.com/
- https://docs.cohere.com/